

Lucas da Silva dos Santos
Matheus Zanivan Andrade
Rafael Nascimento Lourenço

Geração procedural de mapas de ilhas 2d com biomas através de técnicas de segmentação de imagem

São Paulo - Brasil

2023

Lucas da Silva dos Santos
Matheus Zanivan Andrade
Rafael Nascimento Lourenço

Geração procedural de mapas de ilhas 2d com biomas através de técnicas de segmentação de imagem

Modelo canônico de trabalho monográfico
acadêmico em conformidade com as normas
ABNT apresentado à comunidade de usuários
L^AT_EX.

Senac: Serviço Nacional de Aprendizagem Comercial
Bacharelado em ciência da computação

Orientador: Lauro César Araujo
Coorientador: Equipe abnT_EX2

São Paulo - Brasil

2023

Obtenha a ficha catalográfica junto a biblioteca.
Substitua o arquivo ficha.pdf pela versão obtida lá.

Lucas da Silva dos Santos
Matheus Zanivan Andrade
Rafael Nascimento Lourenço

Geração procedural de mapas de ilhas 2d com biomas através de técnicas de segmentação de imagem

Modelo canônico de trabalho monográfico
acadêmico em conformidade com as normas
ABNT apresentado à comunidade de usuários
L^AT_EX.

Trabalho aprovado. São Paulo - Brasil, 24 de novembro de 2012:

Lauro César Araujo
Orientador

Professor
Convidado 1

Professor
Convidado 2

São Paulo - Brasil
2023

*Este trabalho é dedicado às crianças adultas que,
quando pequenas, sonharam em se tornar cientistas.*

Agradecimentos

Os agradecimentos principais são direcionados à Gerald Weber, Miguel Frasson, Leslie H. Watter, Bruno Parente Lima, Flávio de Vasconcellos Corrêa, Otavio Real Salvador, Renato Machnievscz¹ e todos aqueles que contribuíram para que a produção de trabalhos acadêmicos conforme as normas ABNT com L^AT_EX fosse possível.

Agradecimentos especiais são direcionados ao Centro de Pesquisa em Arquitetura da Informação² da Universidade de Brasília (CPAI), ao grupo de usuários *latex-br*³ e aos novos voluntários do grupo *abnT_EX2*⁴ que contribuíram e que ainda contribuirão para a evolução do abnT_EX2.

¹ Os nomes dos integrantes do primeiro projeto abnT_EX foram extraídos de <<http://codigolivre.org.br/projects/abntex/>>

² <<http://www.cpai.unb.br/>>

³ <<http://groups.google.com/group/latex-br>>

⁴ <<http://groups.google.com/group/abntex2>> e <<http://abntex2.googlecode.com/>>

*“Não vos amoldeis às estruturas deste mundo,
mas transformai-vos pela renovação da mente,
a fim de distinguir qual é a vontade de Deus:
o que é bom, o que Lhe é agradável, o que é perfeito.
(Bíblia Sagrada, Romanos 12, 2)*

Sumário

1	INTRODUÇÃO	13
1.1	Contexto	13
1.2	Justificativa	14
1.3	Objetivos	14
2	FUNDAMENTAÇÃO TEÓRICA	15
2.1	Inteligência Artificial	15
2.1.1	Aprendizado de Máquina	16
2.1.1.1	Rede neural artificial	17
2.1.1.2	Funções de ativação	18
2.1.2	Aprendizado profundo	19
2.1.2.1	Redes neurais profundas	19
2.1.3	Redes neurais convolucionais	20
2.1.4	Visão computacional	21
2.1.4.1	Pré-processamento de Imagens	22
2.1.4.2	Detectação de objetos	22
2.1.4.3	Segmentação de imagem	22
2.1.5	Algoritmos de segmentação	22
2.1.5.1		22
2.2	Geração procedural	22
2.2.1	Diagrama de Voronoi	22
2.2.2	Mapas de ilhas 2d com biomas	22
3	DESENVOLVIMENTO	23
	Conclusão	25
	REFERÊNCIAS	27

1 Introdução

1.1 Contexto

A indústria de jogos digitais cresce mais a cada dia, segundo a consultora Newzoo ([SANTANA, 2022](#)) essa indústria tende a ultrapassar em 2023 os US\$ 200,0 bilhões (aproximadamente R\$ 1 trilhão). Novos jogos são produzidos e publicados diariamente e somente na plataforma digital Steam, foram publicados 10.963 novos títulos em 2022 ([CLEMENT, 2023](#)).

Por outro lado, as empresas de desenvolvimento de jogos continuam a trabalhar incessantemente para atender a uma demanda de mercado que cresceu 2,5% no Brasil em 2022 ([GIANNOTTI, 2022](#)). No entanto, para que um jogo chegue ao consumidor final é preciso passa por diversos processos de criação extremamente complexos e rigorosos. Uma equipe de desenvolvimento, composta por designers e programadores, precisa dedicar muitos recursos para a elaboração de mapas 2D e 3D, com o objetivo de garantir a melhor aparência e otimização do jogo.

O custo de produção de jogos varia bastante, dependendo do tamanho e da complexidade do projeto. Por exemplo, a empresa Rockstar Games revelou que o jogo *Grand Theft Auto V* custou cerca de 265 milhões de dólares para ser produzido e comercializado ([BAIRD, 2021](#)). Isso destaca a importância de acelerar o processo de desenvolvimento e reduzir custos, sem comprometer a qualidade do produto final.

Uma solução para reduzir custos e economizar tempo é a utilização da geração procedural de conteúdo (PCG), que permite gerar mapas de forma automatizada. A PCG é uma técnica que trata da criação automática de conteúdos ([ARAÚJO, 2018](#)). Com a utilização da técnica PCG, as empresas conseguem gerar mapas de forma rápida e eficiente, sem a necessidade de investir em recursos humanos para criação manual de cada elemento. Além disso, a PCG permite a criação de conteúdo personalizado e variado, garantindo uma experiência única para cada usuário. Isso resulta em uma redução significativa de custos e em um aumento da eficiência operacional da empresa, uma vez que a criação de conteúdo manualmente é uma tarefa demorada e dispendiosa. Com a PCG, as empresas podem produzir uma grande quantidade de conteúdo de forma rápida e, portanto, podem lançar seus jogos mais rapidamente no mercado.

"Bill Gates, um dos fundadores da Microsoft, diz que o desenvolvimento da inteligência artificial (IA) é o avanço tecnológico mais importante em décadas" ([GERKEN, 2023](#)). É possível ver a relevância do tema e justamente por isso que este trabalho acompanhara o desenvolvimento de um modelo de inteligência artificial e utilizará os resultados em um

diagrama de Veronoi.

1.2 Justificativa

Este trabalho foi concebido em busca de fazer a junção de um modelo de inteligência artificial convolucional com a decomposição de espaço do diagrama de Veronoi, bem como disponibilizar mais uma forma de geração procedural de conteúdo que seja pratico, de baixo custo e possua facilidade na configuração de parâmetros.

1.3 Objetivos

O objetivo geral deste trabalho explora técnicas e algoritmos que permeiam os ramos de inteligência artificial com foco em identificar contornos em imagens e computação gráfica centrado em gerar mapas usando heurísticas. Ademais visto especificamente temos como objetivos:

- Encontrar um dataset para treinar a inteligência artificial que irá identificar contornos em imagens
- Treinar uma inteligência artificial para identificar contornos em imagens
- Testar algoritmos de gerar ruídos para criar o mapa
- Aplicar um algoritmo para reconhecer a imagem com o contorno e gerar como saída a imagem do mapa gerado

2 Fundamentação teórica


Este capítulo tem objetivo de apresentar conceitos necessários para entendimento do trabalho.

2.1 Inteligência Artificial

Inteligência artificial é uma técnica científica que simula o pensamento humano de forma que possa ser executado em uma máquina, podendo ser utilizada para criar soluções com uma linha de progressão parecida ao raciocínio lógico como conhecemos. Isto permite ao computador reconhecer e interpretar o mundo ao redor com imagens e textos criando uma ampla área de atuação que otimiza tarefas antes só realizadas por seres humanos (SILVA; MAIRINK, 2019).

Este ramo é complexo por se tratar de uma representação cognitiva, se torna necessário usar uma base com diversas áreas científicas como psicologia, biologia, lógica matemática, linguística, engenharia, filosofia, entre outras. E pode ser usado para diversos problemas específicos como, por exemplo, definir as boas rotas para algum processo logístico (GOMES, 2010).

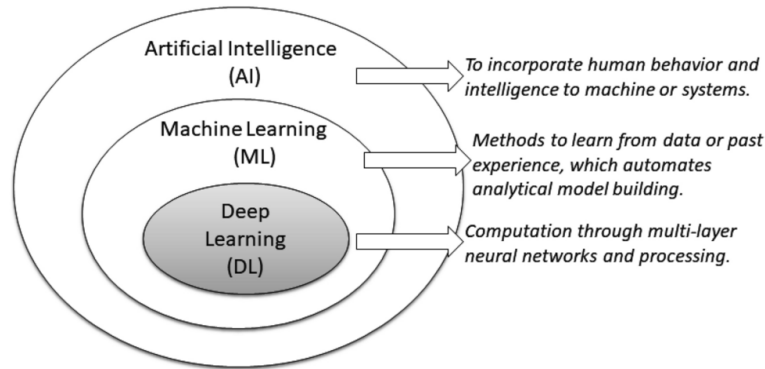
Figura 1 – Diagrama de aprendizado de máquina



Fonte: MONARD e BARANAUKAS (2000)

Segundo Sarker (2021) existe três tópicos sobre inteligência artificial muito populares sendo eles, inteligência artificial, aprendizado de máquina e aprendizado profundo como segue na imagem Figura 2.

Figura 2 – Diagrama de Venn sobre relação entre os tópicos de inteligência artificial



Fonte: [Sarker \(2021\)](#)

2.1.1 Aprendizado de Máquina

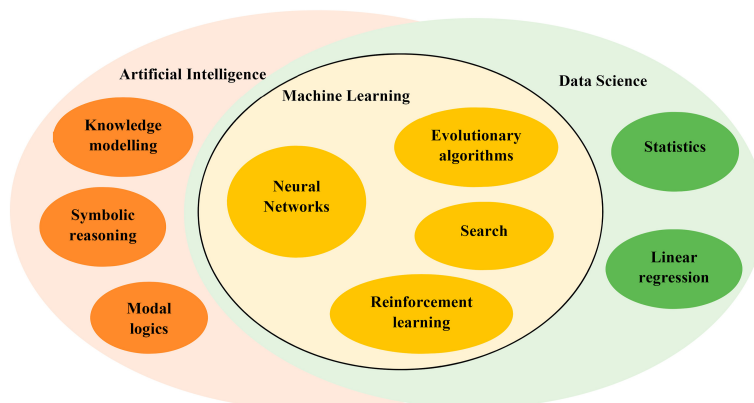
Segundo [Woschank, Rauch e Zsifkovits \(2020\)](#), aprendizado de máquina é uma subcategoria de inteligência artificial que se refere a detecção de padrões importantes de uma base de dados. As ferramentas utilizadas aumentam a eficiência dos algoritmos para lidar com bases de dados grandes.

Portanto, essa técnica permite ao computador melhorar os resultados com base na experiência, isso indica uma relação direta entre o quanto o programa consumiu de dados e qualidade da solução do problema ([BROWN, 2021](#)).

Dentro desse nicho existem outros como: redes neurais, algoritmos evolucionários, algoritmos de busca, aprendizado por reforço, dentre outros. ([SIRCAR et al., 2021](#)).

Existe relação direta de conceitos entre inteligência artificial, aprendizado de máquina e ciência de dados conforme mostrado na Figura 3.

Figura 3 – Diagrama de aprendizado de máquina

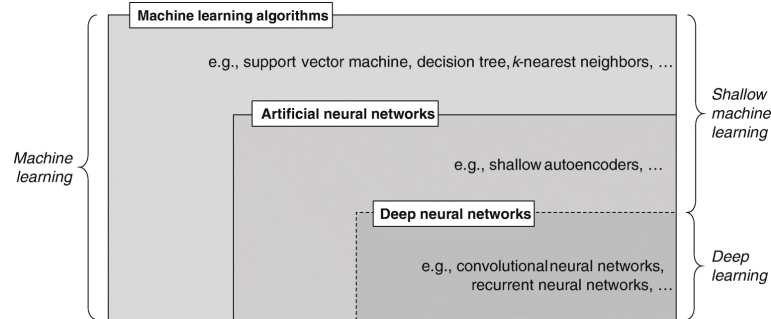


Fonte: [Sircar et al. \(2021\)](#)

É possível observar uma hierarquia entre aprendizado de máquina e os principais

termos sendo eles redes neurais artificiais e aprendizado profundo com base em Janiesch, Zschech e Heinrich (2021) mostrado no diagrama da Figura 4.

Figura 4 – Diagrama de Venn sobre tópicos de aprendizado de máquina



Fonte: Janiesch, Zschech e Heinrich (2021)

2.1.1.1 Rede neural artificial

Um neurônio é uma unidade de processamento fundamental para uma rede neural (HAYKIN, 1999).




Figura 5 – Modelo de um neurônio não-linear (HAYKIN, 1999).

Observando a figura 5 vemos o funcionamento de um neurônio k . Os sinais de entradas são partes de um vetor x de tamanho n , sendo o vetor composto por x_1, x_2, \dots, x_n , essas componentes são combinadas em uma soma ponderada utilizando seus respectivos pesos, $w_{k1}, w_{k2}, \dots, w_{kn}$, formando assim a seguinte equação (MARTI; BARROS, 2017 apud HAYKIN, 1999):

$$v_k = \sum_{i=1}^n (x_i * w_{ki})$$

O resultado dessa equação produz o potencial de ativação v_k , esse resultado é somado com o *bias* ou viés b_k para manipular a saída y_k do neurônio, essa soma é posta em uma função não-linear nomeada de função de ativação $\varphi(\cdot)$, essas funções mapeiam a saída em um intervalo $[0, 1]$ ou $[1, -1]$. A função de saída pode ser representada com a seguinte equação (MARTI; BARROS, 2017 apud HAYKIN, 1999):

$$y_k = \varphi(v_k + b_k)$$

O aprendizado ocorre na fase de treinamento onde é ajustando os pesos w_k e o viés b_k de cada neurônio k . Os pesos w_k são utilizados para calcular a taxa de crescimento da função e o viés b_k é necessário para descolar a saída da função. Com isso é possível modelar uma função linear $y = w^T * x + b$ (MARTI; BARROS, 2017).

Para cada amostra o modelo compara os resultados dos valores atuais dos pesos w_k e viés b_k com o resultado esperado(alvo). Uma função custo(*cost function*) é utilizada para gerar um vetor de gradientes e para quantificar o erro encontrado para a configuração atual do modelo. O modelo atualiza os pesos w_k e os viés b_k no sentido contrário do vetor de gradientes, buscando minimizar a função de custo de acordo com uma taxa de aprendizado(*learning rate*) (MARTI; BARROS, 2017).

Nas redes neurais os neurônios são organizados em grupos de unidade de processamento chamados camadas. A primeira e a ultima camada são nomeadas de camada de entrada e camada de saída e as demais de camadas ocultas. As camadas mais próximas da entrada são responsáveis por identificar características mais primitivas e a seguintes combinam essas informações para identificar padrões mais complexos (MARTI; BARROS, 2017).

2.1.1.2 Funções de ativação

Existem três tipos básicos de função de ativação (HAYKIN, 1999):

1. Função de ativação com limite (*threshold*)

$$\varphi(x) = \begin{cases} 1 & \text{se } x \geq 0 \\ 0 & \text{se } x < 0 \end{cases}$$




Figura 6 – Grafico da função *threshold* (HAYKIN, 1999).

AJUSTES E CONTINUA

link das imagens <http://www2.decom.ufop.br/imobilis/redes-neurais-funcoes-de-ativacao/>

2.1.2 Aprendizado profundo

O aprendizado profundo é uma área do aprendizado de máquina caracterizada por utilizar dados brutos como entrada e descobrir as representações necessárias para permitir o mapeamento adequado e assim tornando as soluções mais simples (MARTI; BARROS, 2017 apud LECUN; BENGIO; HINTON, 2015).

Segundo LeCun, Bengio e Hinton (2015), o aprendizado profundo são métodos de representação de aprendizado com vários níveis, obtidos por meio da decomposição de módulos simples e lineares, que transformam a representação de um nível em uma representação mais alta e abstrata. Por exemplo a representação de uma imagem é transformada em informações que identificam objetos.

Dividindo um problema complexo em problemas menores torna os métodos especializados, viabilizando tarefas mais complexas, depois essas tarefas que foram divididas são recombinadas e é gerado uma solução do problema (MARTI; BARROS, 2017).

Utilizando o exemplo anterior, reconhecimento de imagem, cada um desses métodos especializados seria responsável por reconhecer uma parte da imagem, como bordas, objetos, tamanho, etc. E após a junção desses métodos é feita a predição da imagem (MARTI; BARROS, 2017).

2.1.2.1 Redes neurais profundas

A principal diferença entre uma rede neural convencional e uma rede neural profunda é a quantidade de camadas, uma rede neural profunda possui mais de uma camada de processamento ([MARTI; BARROS, 2017](#) apud [HAYKIN, 1999](#)).





Figura 7 – Comparação de uma rede neural convencional com uma rede neural profunda.

2.1.3 Redes neurais convolucionais

Uma rede neural convolucional é análoga à rede neural artificial, i.e., feita de neurônios que otimizam o aprendizado através dele mesmo. A principal diferença é que a rede neural convolucional é amplamente utilizada em soluções que detectam padrões em imagens, logo existem funcionalidades específicas da própria arquitetura para essa tarefa ([O'SHEA; NASH, 2015](#)).

De acordo com [Sarker \(2021\)](#) uma arquitetura básica de uma rede neural convolucional tem as seguintes camadas: convolucional, pooling e totalmente conectada.

Figura 8 – Camadas principais de uma rede neural convolucional



Fonte: [Sarker \(2021\)](#)

Camada convolucional é essencial para esse tipo de arquitetura e usa um filtro — ou kernel — para aplicar na imagem e direcionar para o próximo neurônio. Esse filtro é

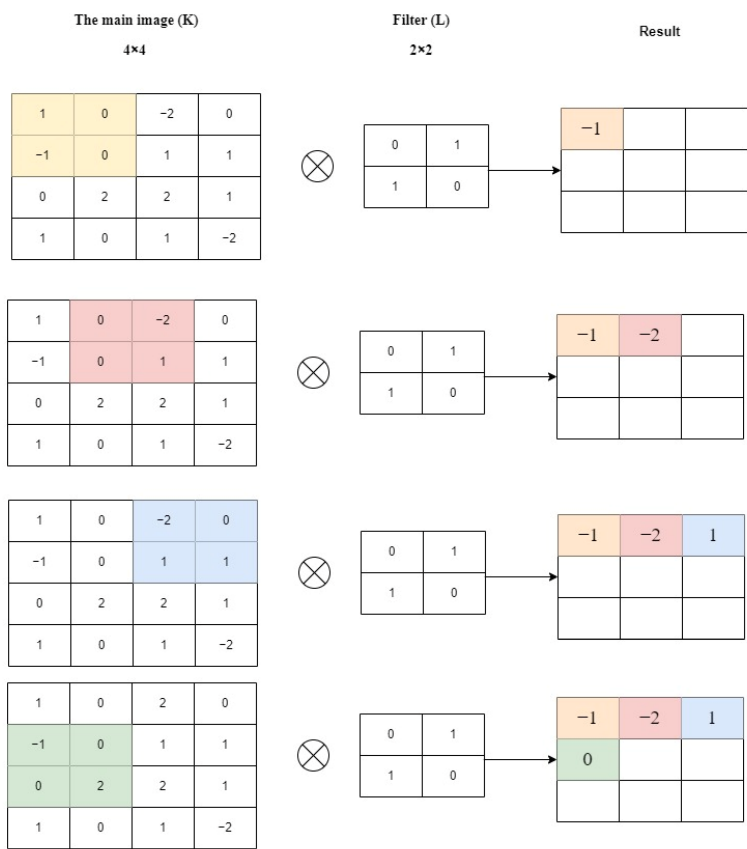
uma matriz de números que terá uma operação aplicada em todos os píxeis da imagem — que também é representado por matriz(es) — as informações cruciais para esse filtro são: tamanho, largura e pesos. Isto é utilizado para extrair características com uma base matemática, criando uma relação direta entre um píxel e os píxeis ao redor. Os pesos começam de forma pseudoaleatórias e são ajustados no decorrer do aprendizado. O resultado dessa camada é chamado de mapa de características.

O tamanho da saída será baseado na fórmula abaixo sendo os tamanhos I da imagem, F do filtro e a S da saída.

$$Ix - Fx + 1 = Sx$$

$$Iy - Fy + 1 = Sy$$

Figura 9 – Exemplo de um filtro



Fonte: [Taye \(2023\)](#)

2.1.4 Visão computacional

A visão computacional avança cada vez mais, aproximando os computadores da capacidade visual humana. Segundo Horst Haußecker e Bernd Jähne no livro "Computer Vision and Applications" ([HAUßECKER BERND JÄHNE, 1999](#)), a visão computacional é uma área da computação que se dedica à interpretação de imagens por meio de algoritmos

e técnicas de processamento de imagens. Essa área abrange a aquisição, processamento e análise de imagens, com o objetivo de extrair informações úteis para resolver problemas específicos.

A visão é um elemento crucial para capacitar a inteligência artificial a realizar diversas tarefas. A fim de replicar a visão humana, é necessário que as máquinas sejam capazes de adquirir, processar, analisar e compreender imagens. (MARR, 2019)

Na Figura 10 podemos ver uma analogia entre a forma como uma imagem é processada pelo cérebro humano e a forma como é processada por um sistema computacional.

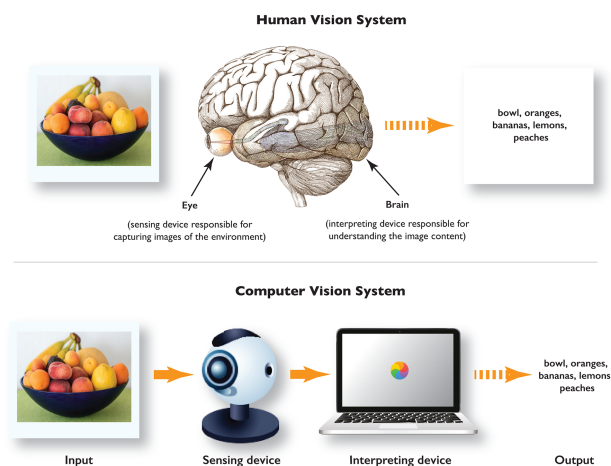


Figura 10 – Comparação entre a forma de como o cérebro humano e um computador processam informações (BABICH, 2020).

2.1.4.1 Pré-processamento de Imagens

2.1.4.2 Detecção de objetos

2.1.4.3 Segmentação de imagem

2.1.5 Algoritmos de segmentação

2.1.5.1

2.2 Geração procedural

2.2.1 Diagrama de Voronoi

O diagrama de Voronoi é gerado a partir das distâncias euclidianas entre os vizinhos mais próximos de um conjunto de pontos do plano (SANTOS, 2016). Esse diagrama possui uma gama de utilizações, *e. g.*, estudar epidemias, encontrar o ponto mais próximo,

calcular a precipitação de uma área, estudar os padrões de crescimento das florestas, etc, (POLÍGONOS, 2023). O diagrama de Voronoi sera utilizado na geração de biomas com o algoritmo de Fortune.

2.2.2 Mapas de ilhas 2d com biomas

3 Desenvolvimento

Conclusão

Sed consequat tellus et tortor. Ut tempor laoreet quam. Nullam id wisi a libero tristique semper. Nullam nisl massa, rutrum ut, egestas semper, mollis id, leo. Nulla ac massa eu risus blandit mattis. Mauris ut nunc. In hac habitasse platea dictumst. Aliquam eget tortor. Quisque dapibus pede in erat. Nunc enim. In dui nulla, commodo at, consectetur nec, malesuada nec, elit. Aliquam ornare tellus eu urna. Sed nec metus. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

Phasellus id magna. Duis malesuada interdum arcu. Integer metus. Morbi pulvinar pellentesque mi. Suspendisse sed est eu magna molestie egestas. Quisque mi lorem, pulvinar eget, egestas quis, luctus at, ante. Proin auctor vehicula purus. Fusce ac nisl aliquam ante hendrerit pellentesque. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Morbi wisi. Etiam arcu mauris, facilisis sed, eleifend non, nonummy ut, pede. Cras ut lacus tempor metus mollis placerat. Vivamus eu tortor vel metus interdum malesuada.

Sed eleifend, eros sit amet faucibus elementum, urna sapien consectetur mauris, quis egestas leo justo non risus. Morbi non felis ac libero vulputate fringilla. Mauris libero eros, lacinia non, sodales quis, dapibus porttitor, pede. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Morbi dapibus mauris condimentum nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Etiam sit amet erat. Nulla varius. Etiam tincidunt dui vitae turpis. Donec leo. Morbi vulputate convallis est. Integer aliquet. Pellentesque aliquet sodales urna.

Referências

ARAÚJO, W. O. de. *Geração procedural de conteúdo para criação de fases de jogos educativos*. Dissertação (Mestrado) — Universidade Federal do Rio Grande do Norte, 2018. Citado na página 13.

BABICH, N. *What Is Computer Vision? How Does It Work?* 2020. <<https://xd.adobe.com/ideas/principles/emerging-technology/what-is-computer-vision-how-does-it-work/>>. Acesso em: 18-05-2023. Citado na página 22.

BAIRD, S. *How Much Grand Theft Auto 5 Cost To Make*. 2021. <<https://screenrant.com/grand-theft-auto-5-how-much-cost-make/>>. Acessado: 2023-03-20. Citado na página 13.

BROWN, S. *Machine learning, explained*. 2021. <<https://mitsloan.mit.edu/ideas-made-to-matter/machine-learning-explained>>. Acessado: 2023-05-11. Citado na página 16.

CLEMENT, J. *Number of games released on Steam worldwide from 2004 to 2022*. 2023. <<https://www.statista.com/statistics/552623/number-games-released-steam/>>. Acessado: 2023-03-14. Citado na página 13.

GERKEN, T. *Inteligência artificial é avanço mais importante da tecnologia em décadas, diz Bill Gates*. 2023. <<https://www.bbc.com/portuguese/articles/cqqz6w6nzt1o>>. Acessado: 2023-03-26. Citado na página 13.

GIANNOTTI, R. *Pesquisa Game Brasil 2022 mostra que 74,5% dos brasileiros jogam games regularmente*. 2022. <<https://www.adrenaline.com.br/games/pesquisa-game-brasil-2022-mostra-que-745-dos-brasileiros-jogam-games-regularmente/>>. Acessado: 2023-03-12. Citado na página 13.

GOMES, D. D. S. *Inteligência artificial: Conceitos e aplicações*. *Olhar Científico - Faculdades Associadas de Ariquemes*, v. 1, n. 2, p. 234–246, 2010. Disponível em: <https://www.professores.uff.br/screspo/wp-content/uploads/sites/127/2017/09/ia_intro.pdf>. Citado na página 15.

HAUBECKER BERND JÄHNE, B. J. H. *Handbook of computer vision and applications*. [S.l.]: ACADEMIC PRESS, 1999. ISBN 0-12-379770-5 (set). — ISBN 0-12-379771-3 (v. 1). Citado na página 21.

HAYKIN, S. S. *Neural Networks: A Comprehensive Foundation*. [S.l.]: Prentice Hall, 1999. Citado 4 vezes nas páginas 17, 18, 19 e 20.

JANIESCH, C.; ZSCHECH, P.; HEINRICH, K. Machine learning and deep learning. *Electronic Markets*, v. 31, n. 3, p. 685–695, Sep 2021. ISSN 1422-8890. Disponível em: <<https://doi.org/10.1007/s12525-021-00475-2>>. Citado na página 17.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015. Citado na página 19.

MARR, B. *7 Amazing Examples Of Computer And Machine Vision In Practice*. 2019. <<https://www.forbes.com/sites/bernardmarr/2019/04/08/7-amazing-examples-of-computer-and-machine-vision-in-practice/?sh=4ee6506b1018>>. Acesso em: 18-05-2023. Citado na página 22.

MARTI, L.; BARROS, T. Aprendizado profundo: Fundamentos, histórico e aplicações. In: SBC. *Anais do XIV Simpósio Brasileiro de Sistemas Colaborativos*. [S.l.], 2017. Citado 4 vezes nas páginas 17, 18, 19 e 20.

MONARD, M. C.; BARANAUKAS, J. A. *Aplicações de Inteligência Artificial: Uma Visão Geral*. 2000. <<https://dcm.ffclrp.usp.br/~augusto/publications/2000-laptec.pdf>>. Citado na página 15.

O'SHEA, K.; NASH, R. An introduction to convolutional neural networks. *CoRR*, abs/1511.08458, 2015. Disponível em: <<http://arxiv.org/abs/1511.08458>>. Citado na página 20.

POLÍGONOS. *Polígonos de Thiessen ou Voronoi- Como gerar e para que utilizá-los*. 2023. <<https://www.bbc.com/portuguese/articles/cqz6w6n1o>>. Acessado: 2023-03-26. Citado na página 22.

SANTANA, W. *Games vão movimentar R\$ 1 tri em 2023 e empresas estão de olho nisso*. 2022. <<https://www.infomoney.com.br/negocios/games-movimentar-r-1-tri-em-2023-empresas-de-olho/>>. Acessado: 2023-03-15. Citado na página 13.

SANTOS, P. R. S. dos. *Diagrama de voronoi: Uma Exploração nas Distâncias Euclidiana e do Táxi*. Dissertação (Mestrado) — Universidade Tecnológica Federal do Paraná - UTFPR, 2016. Citado na página 22.

SARKER, I. H. Deep learning: A comprehensive overview on techniques, taxonomy, applications and research directions. *SN Computer Science*, v. 2, n. 6, p. 420, Aug 2021. ISSN 2661-8907. Disponível em: <<https://doi.org/10.1007/s42979-021-00815-1>>. Citado 3 vezes nas páginas 15, 16 e 20.

SILVA, J. A. S. d.; MAIRINK, C. H. P. Inteligência artificial. *LIBERTAS: Revista de Ciências Sociais Aplicadas*, v. 9, n. 2, p. 64–85, dez. 2019. Disponível em: <<https://famigvirtual.com.br/famig-libertas/index.php/libertas/article/view/247>>. Citado na página 15.

SIRCAR, A. et al. Application of machine learning and artificial intelligence in oil and gas industry. *Petroleum Research*, v. 6, n. 4, p. 379–391, 2021. ISSN 2096-2495. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2096249521000429>>. Citado na página 16.

TAYE, M. M. Theoretical understanding of convolutional neural network: Concepts, architectures, applications, future directions. *Computation*, v. 11, n. 3, 2023. ISSN 2079-3197. Disponível em: <<https://www.mdpi.com/2079-3197/11/3/52>>. Citado na página 21.

WOSCHANK, M.; RAUCH, E.; ZSIFKOVITS, H. A review of further directions for artificial intelligence, machine learning, and deep learning in smart logistics. *Sustainability*,

v. 12, n. 9, 2020. ISSN 2071-1050. Disponível em: <<https://www.mdpi.com/2071-1050/12/9/3760>>. Citado na página 16.